Projeto 2: Quantização de Cores

Introdução às Redes Neurais Artificiais

Ana Flávia Ribeiro de Siqueira (RA: 164906)

Repositório: github.com/afrsiq/redes-neurais/tree/main/projeto-2/main

1. Dataset

A imagem escolhida refere-se ao quadro "Terraço do Café à Noite", pintado por Van Gogh em 1888, em dimensões de 1200 x 2133. Utilizando um identificador de cores online, foi possível chegar a uma paleta de cores modelo para realizar comparações.

Figura 1 - Imagem Original.

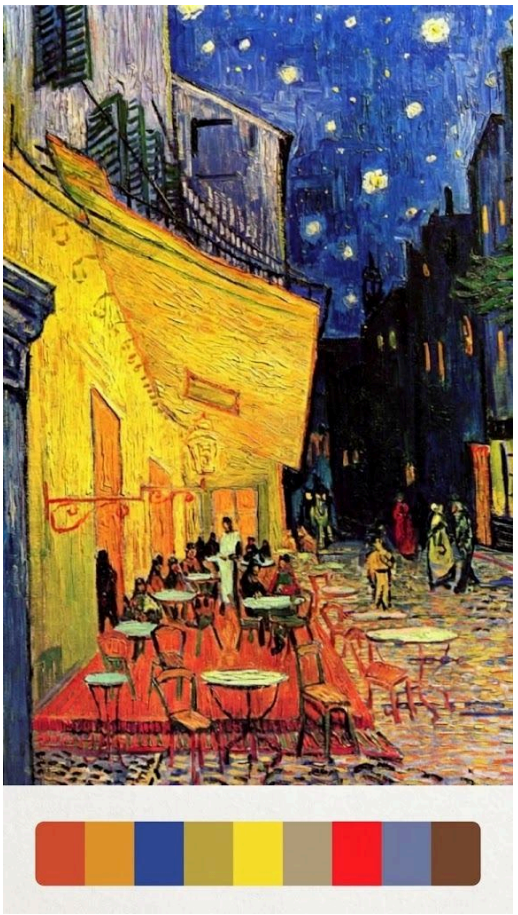

2. Pré-Processamento

A imagem digital original, carregada no espaço de cores RGB de 24 bits (onde cada canal possui valores inteiros de 8 bits sem sinal, variando de 0 a 255), é convertida para uma matriz numérica através da biblioteca PIL e do NumPy.

Para que os algoritmos de aprendizado não supervisionado (SOM e GNG) processem os dados adequadamente, a imagem de dimensões originais

$(Altura \times Largura \times 3)$ é transformada (*achatada*) em um conjunto de dados bidimensional de formato $(H \times W, 3)$, onde cada linha passa a representar um vetor tridimensional independente $[R, G, B]$ que corresponde a uma única amostra de pixel no espaço cromático.

Posteriormente, aplica-se a normalização linear dos dados dividindo todos os valores por 255.0. Essa operação converte as variáveis de inteiros de 8 bits para números de ponto flutuante (*float*) no intervalo normalizado $[0.0, 1.0]$. A normalização é uma etapa crítica para evitar desvios numéricos, garantir a estabilidade matemática no cálculo das distâncias euclidianas e assegurar que todos os canais de cor possuam a mesma ponderação durante a competição das unidades neurais.

3. Rede SOM

A Self-Organizing Map (Mapa Auto-Organizável) é uma rede neural artificial não supervisionada baseada em aprendizado competitivo. A sua principal característica é a capacidade de mapear o espaço de entrada de alta dimensionalidade (neste caso, o espaço de cores RGB tridimensional) para uma grade topológica bidimensional discreta, preservando as relações de vizinhança originais (topologia).

Os principais hiperparâmetros configurados e testados nos experimentos da SOM foram:

a. Tamanho do Grid $(height\ x\ weight)$: Define a capacidade de discretização e o número total de protótipos de cores da rede. Foram testadas cinco malhas distintas (2×2, 4×4, 8×8, 12×12 e 16×16), variando de 4 até 256 neurônios. Grids maiores reduzem o Erro de Quantização por aumentarem a paleta de cores disponível, mas exigem maior rigor na preservação topológica.
b. Taxa de Aprendizado $(lr,\ \eta)$: Controla a magnitude da alteração que os pesos sinápticos sofrem a cada iteração quando estimulados pela amostra de entrada. Valores menores (como 0.1 no Caso 1) garantem estabilidade nas atualizações, enquanto valores maiores (0.5 nos Casos 2 e 3) aceleram a convergência inicial, exigindo um decaimento exponencial adequado para permitir o ajuste fino.
c. Épocas: O número total de ciclos de treinamento em que todo o conjunto de pixels é apresentado de forma iterativa à rede. Variações entre 1000 e 3000 épocas foram testadas para avaliar o impacto na estabilização dos protótipos cromáticos.
d. Raio Inicial de Vizinhança ($\sigma_{initial}$): Determina o alcance geográfico da influência que o neurônio vencedor (*Best Matching Unit* - BMU) exerce sobre os seus vizinhos na grade 2D durante a fase cooperativa. Valores amplos no início ($raio = max$) forçam uma organização global da paleta, enquanto valores moderados ($raio = max/2$) evitam distorções excessivas nas malhas menores.

Tabela 1 - Hiperparâmetros Utilizados na Rede SOM

Casos	Taxa (η)	Épocas	Raio (σ)
Caso 1	0.1	1000	max/2
Caso 2	0.5	2000	max/2
Caso 3	0.5	3000	max

Fonte: Próprio Autor, 2026.

4. Rede GNG (Growing Neural Gas)

O GNG é uma rede neural de crescimento dinâmico baseada em grafos que aprende distribuições topológicas sem a necessidade de fixar antecipadamente o número de neurônios ou a geometria da rede. Os nós e as conexões (arestas) são inseridos e removidos iterativamente com base no acumulado de erro local.

Os principais hiperparâmetros e configurações testadas na GNG foram:

a. Número máximo de nós *(max_nodes):* Define o limite de capacidade da rede. Foram avaliadas estruturas com $8, 16, 32, 64$ e 256 neurônios, permitindo comparar diretamente o desempenho de quantização com os tamanhos equivalentes da SOM.
b. Taxas de Aprendizado (η_b e η_n):
    i. η_b (eb): Taxa de aprendizado aplicada especificamente ao neurônio vencedor (BMU principal) para puxá-lo em direção ao pixel de entrada.
    ii. η_n (en): Taxa de aprendizado aplicada aos nós vizinhos conectados diretamente por arestas à BMU. O valor de η_n é mantido significativamente menor que η_b (10^{-4} contra 10^{-2}) para assegurar que a vizinhança acompanhe o movimento sem desestruturar os agrupamentos formados.
c. Frequência de Inserção de Nós (λ): Define o intervalo de passos (iterações) em que um novo neurônio é inserido na rede. Um λ menor (25) insere nós rapidamente, adaptando-se a detalhes complexos, enquanto um λ maior (100) dá mais tempo para os nós existentes estabilizarem suas cores antes de expandir o grafo.
d. Idade Máxima da Aresta (a_{max}): Controla o tempo de vida de uma conexão. Se uma aresta não for revalidada (por não unir as duas BMUs de um pixel) durante um número de passos superior a a_{max}, ela é removida. Valores menores ($a_{max} = 50$) ajudam a podar conexões obsoletas e isolar melhor os limites entre cores distintas.
e. Fator de Redução de Erro (α): Coeficiente utilizado para atenuar o erro acumulado dos nós vizinhos quando um novo neurônio intermediário é

inserido entre eles, garantindo que o erro seja distribuído de forma proporcional.

Tabela 2 - Hiperparâmetros Utilizados na Rede SOM

Casos	Taxas ($\eta_{b,}\ \eta_{n}$)	Épocas	Parâmetros ($\alpha,\ \lambda,\ \alpha_{max}$)
Caso 1	0.01, 0.0001	1000	0.5, 50, 90
Caso 2	0.01, 0.0001	2000	0.5, 100, 50
Caso 3	0.1, 0.001	2000	0.5, 25, 50

Fonte: Próprio Autor, 2026.

5. **Erro de Quantização**

Mede a fidelidade visual e a perda de informação de cor da imagem quantizada em relação à original. O EQ calcula a distância euclidiana média, no espaço tridimensional RGB, entre cada pixel original da imagem e o vetor de pesos do seu respectivo neurônio vencedor (*Best Matching Unit* - BMU):

$EQ = \frac{1}{N}\sum_{i=1}^{N} ||X_i - W_{BMU(i)}||$, onde N é o número total de pixels da imagem, X_i é o pixel original e $W_{BMU(i)}$ é o protótipo de cor atribuído pelo neurônio vencedor.

Quanto menor o EQ, mais próxima a imagem reconstruída estará da original. O valor ideal é o mais próximo possível de 0.0. O erro diminui naturalmente à medida que se aumenta a quantidade de neurônios (tamanho do grid ou número de nós), pois a rede passa a dispor de uma paleta de cores mais rica e específica.

6. **Erro Topológico**

Mede O grau de preservação da estrutura espacial e das relações de vizinhança do espaço de entrada de alta dimensionalidade para a estrutura da rede. A rede GNG avalia a proporção de amostras em que a 1ª e a 2ª BMUs **não** possuem uma aresta ativa conectando-as diretamente no grafo dinâmico.

$ET = \frac{1}{N}\sum_{i=1}^{N} u(i)$, onde $u(i) = 1$ se os dois neurônios mais próximos não forem vizinhos/conectados, e, caso contrário, 0.

Um ET baixo (próximo de 0.0) indica que a rede conseguiu mapear cores semanticamente semelhantes em neurônios próximos, garantindo continuidade e evitando "dobras" ou rupturas na topologia. Valores elevados revelam que a rede sofreu distorções espaciais, mapeando cores correlacionadas em regiões distantes da estrutura.

7. Resultados da Rede SOM

Figura 2 - Erros de Quantização e Topológico da Rede SOM (Caso 1, 2 e 3)

a. Caso 1: Utilizando uma taxa de aprendizado conservadora (0.1), a rede evitou perturbações excessivas nas épocas iniciais. O Erro de Quantização (EQ) decresceu consistentemente à medida que a grade aumentou, partindo de 0.3367 no grid 2×2 até atingir 0.0536 no grid 16×16. O erro topológico manteve-se extremamente baixo e controlado em todas as resoluções da malha (variando de 0.0000 até 0.0111), demonstrando que a vizinhança Gaussiana inicial de $max/2$ foi ideal para preservar a continuidade do espaço cromático sem introduzir rupturas ou dobras na topologia.

b. Caso 2: A combinação de uma taxa mais agressiva com um período de treinamento estendido favoreceu o ajuste fino nas malhas de maior densidade. Foi neste caso que se obteve o menor erro de quantização global para a rede SOM na malha de 16×16, registrando $EQ = 0.0516$. Embora o erro topológico tenha apresentado um leve incremento pontual no grid 12×12 ($ET = 0.0140$), o erro permaneceu em patamares excelentes nas demais configurações, provando que o dobro de épocas permitiu estabilizar a convergência dos protótipos de cor.
c. Caso 3: O uso de um raio inicial máximo gerou uma restrição nas fases iniciais do treinamento, forçando a rede inteira a reagir de forma homogênea. Isso prejudicou a quantização nas malhas menores, resultando nos maiores Erros de Quantização do experimento para o grid 2×2 ($EQ = 0.3549$) e 4×4 ($EQ = 0.1769$). Conforme a quantidade de neurônios aumentou, o elevado número de épocas (3000) compensou o impacto inicial, permitindo que a rede convergisse para um EQ competitivo de 0.0540 no grid 16×16, acompanhado de um excelente controle do erro topológico ($ET = 0.0068$).

Figura 3 - Grid de Pesos (Caso 1, 2 e 3)

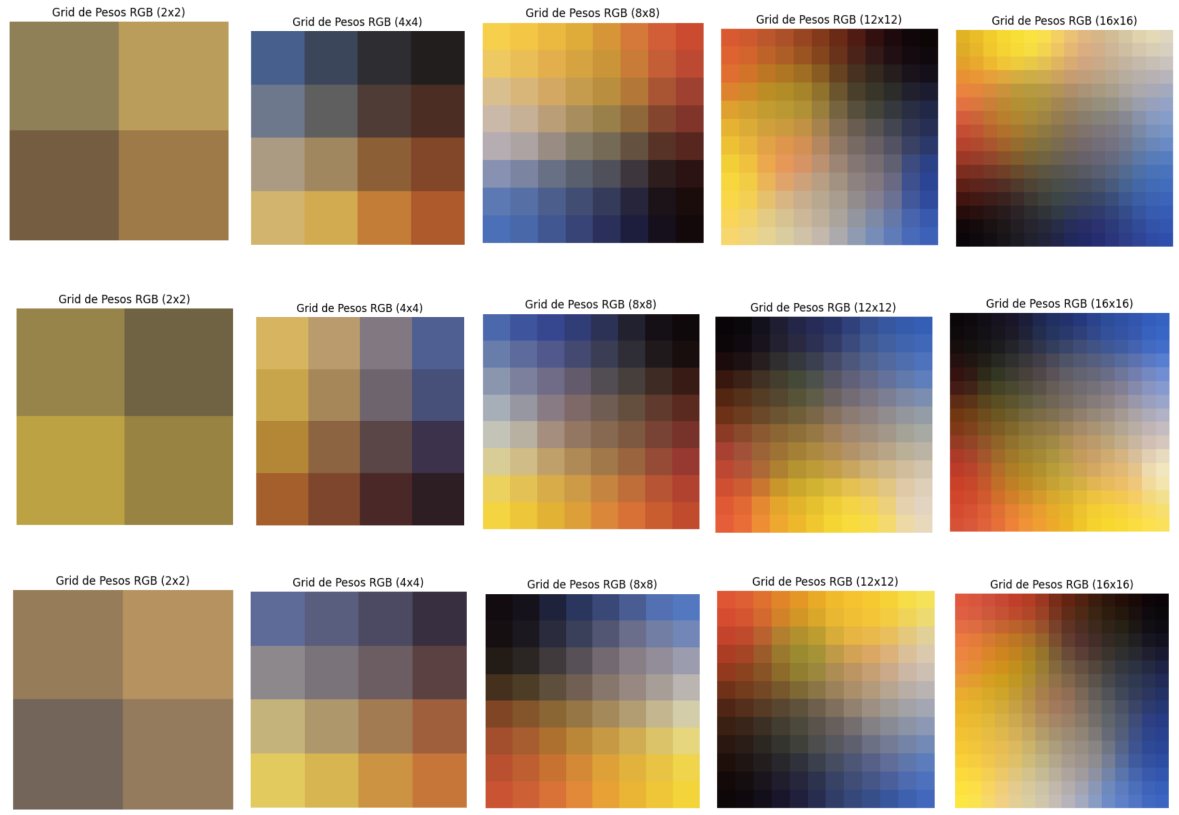

Para a rede SOM, os grids gerados favorecem o primeiro caso de configuração de hiperparâmetros. Observa-se também os grids com 4 neurônios geram imagens chapadas e monocromáticas, devido sua ausência de cores.

8. Resultados da Rede GNG

Figura 4 - Erros de Quantização e Topológico da Rede GNG (Caso 1, 2 e 3)

a. Caso 1: O erro de quantização decresceu de forma expressiva e contínua com o aumento do número de nós, partindo de 0.1417 (8 nós) até atingir 0.0441 na configuração de 256 nós. A alocação dinâmica permitiu capturar os detalhes cromáticos da imagem sem desperdiçar protótipos. O erro topológico manteve-se em patamares baixos em quase toda a linha, registrando excelente consistência nas malhas menores ($ET = 0.0000$ com 16 nós) e fechando com 0.0083 em 256 nós, o que demonstra que as arestas foram bem geridas pelo limiar $a_{max} = 90$.

b. Caso 2: Com mais tempo de treinamento por nó e uma poda mais agressiva de arestas obsoletas ($a_{max} = 50$), a rede obteve melhorias consistentes na representação fina, alcançando um erro de quantização de 0.0425 na malha de 256 nós. O ET apresentou pequenas variações nas redes maiores (0.0127 com 256 nós), reflexo da poda mais restritiva de arestas, que descarta conexões mais rapidamente para isolar os agrupamentos de cores.
c. Caso 3: A inserção rápida combinada com taxas de aprendizado mais altas proporcionou a máxima adaptabilidade da rede na captura de detalhes finos da obra. Foi neste caso que se obteve o menor Erro de Quantização absoluto de todo o experimento para a GNG, registrando 0.0411 na configuração de 256 nós. Devido à alta frequência de inserção de nós ($\lambda = 25$) e às taxas agressivas de atualização, o ET tendeu a subir ligeiramente nas malhas maiores (atingindo 0.0201 com 256 nós), evidenciando um pequeno *trade-off* entre a adaptação dinâmica estrita de cores e a suavidade da topologia do grafo.

9. Conclusão

Como consideração principal, observa-se que a GNG apresentou desempenho superior na redução do Erro de Quantização para um mesmo número de protótipos de cor, uma vez que a sua estrutura dinâmica aloca neurônios de forma adaptativa nas regiões do espaço RGB com maior densidade de pixels, sem desperdiçar capacidade representacional em áreas uniformes. Por outro lado, a rede SOM destacou-se pela estabilidade e pela organização topológica bidimensional rígida, o que permite mapear de forma intuitiva a distribuição contínua da paleta de cores e gerar visualizações estruturadas como os *grids* de pesos e mapas de distância, embora essa rigidez imponha uma leve restrição na aproximação cromática fina.

Em termos de fidelidade visual e aproximação em relação ao quadro original de Van Gogh, o melhor resultado global de todo o experimento foi alcançado pelo Caso 3 da rede GNG na configuração de 256 nós, que atingiu o menor Erro de Quantização absoluto registrado ($EQ = 0,0411$).